

Bootcamp Databricks

Engenharia de Dados dentro da Plataforma Data & AI

I&D Capgemini Brasil, Setembro/2026

Agenda



Aulas	Assunto
Dia 1 – 14/09/2026	Fundamentos de Engenharia de dados e Databricks
Dia 2 – 15/09/2026	SQL, bancos, tabelas e Delta Lake
Dia 3 – 16/09/2026	Unity Catalog, schemas, volumes e governança
Dia 4 – 17/09/2026	Ingestão de dados: batch, incremental, Auto Loader
Dia 5 – 18/09/2026	ETL vs ELT & transformação arquitetura medalhão
Dia 6 – 21/09/2026	Modelagem de dados para Analytics
Dia 7 – 22/09/2026	Processamento distribuído com Spark no Databricks
Dia 8 – 23/09/2026	Streaming e processamento contínuo
Dia 9 – 24/09/2026	Orquestração, Jobs, DataOps e boas práticas
Dia 10 – 25/09/2026	Qualidade, observabilidade, arquitetura e desafio final

Dia 1 - Fundamentos de Engenharia de Dados & Databricks

Introdução completa aos conceitos e arquitetura da plataforma

I&D Capgemini Brasil, Setembro/2026





Databricks para Engenharia de Dados

Fundamentos da Engenharia de Dados

Introdução ao papel da engenharia de dados na geração, transformação e disponibilização dos dados para análises empresariais.

Desafios em Grandes Volumes de Dados


Principais desafios enfrentados, como dados distribuídos, qualidade, governança e escalabilidade em ambientes corporativos.

Conceito de Lakehouse e Plataforma Unificada

Apresentação do conceito Lakehouse e como a plataforma Databricks integra necessidades de engenharia, ciência e IA.

Experiência Prática Inicial

Primeira interação dos alunos com notebooks e execução de códigos simples em Python e SQL na plataforma Databricks.



Objetivos do Dia 1



Introdução à Engenharia de Dados

Compreender as responsabilidades, desafios e áreas de atuação da Engenharia de Dados para um conhecimento alinhado.

Ciclo de Vida dos Dados

Apresentar o ciclo de vida dos dados, mostrando seu percurso desde a origem até o consumo em aplicações e IA.

Paradigma Lakehouse

Introduzir o Lakehouse como arquitetura moderna que integra Data Lakes e Data Warehouses.

Uso da Plataforma Databricks

Capacitar participantes a usar a interface do Databricks e executar atividades práticas com notebooks.


Introdução à Engenharia de Dados

Bootcamp Databricks

I&D Capgemini Brasil



O Problema que Estamos Resolvendo



Desafios dos Dados Empresariais

Os dados apresentam problemas como inconsistência, duplicidade, falta de governança e dispersão entre sistemas, dificultando análises confiáveis.

Importância da Engenharia de Dados

A Engenharia de Dados cria mecanismos para coletar, integrar, transformar e disponibilizar dados de forma estruturada e confiável.

Papel dos Pipelines de Dados

Pipelines organizam o fluxo de movimentação e transformação das informações para garantir qualidade e segurança dos dados.

Arquiteturas e Plataformas Modernas

Arquiteturas modernas suportam escalabilidade, governança e processamento eficiente, fundamentando soluções como Databricks.



O que é Engenharia de Dados e o Papel do Engenheiro

Transformação e Gerenciamento de Dados

Engenharia de Dados transforma dados brutos em informações confiáveis para análise e aplicações diversas.

Construção e Automação de Pipelines

Engenheiros constroem e mantêm pipelines que automatizam ingestão, armazenamento e transformação de dados.

Governança, Segurança e Observabilidade

Definição de padrões de governança, segurança e monitoramento garantem dados seguros e confiáveis.

Colaboração e Arquitetura de Dados

Engenheiros colaboram com times diversos para arquitetar plataformas e suportar IA corporativa.



Ciclo de Vida dos Dados

Bootcamp Databricks

I&D Capgemini Brasil



Etapas do Ciclo de Vida dos Dados

Geração e Ingestão de Dados

Dados são criados por sistemas e depois transportados para armazenamento centralizado.

Armazenamento e Transformação

Informações são armazenadas e transformadas por limpeza, validação e enriquecimento.


Consumo e Aplicações

Dados finalizados são usados em dashboards, IA, relatórios e aplicações operacionais.

Governança e Segurança

Processos transversais garantem qualidade, segurança e orquestração durante todo o ciclo.

O ciclo de vida dos dados:





Fluxo Completo e Áreas Transversais

Fluxo Contínuo de Dados

Dados fluem de diversas fontes como ERP, CRM, APIs para plataformas escaláveis que transformam informação em valor.

Áreas Transversais Essenciais


Governança, segurança, qualidade, observabilidade e orquestração garantem confiabilidade e sustentabilidade do ambiente de dados.

Importância em Ambientes Distribuídos

Essas áreas transversais são cruciais para operar e evoluir plataformas tecnológicas em larga escala e distribuídas.

Visão Integrada para Ecossistemas


Compreender o fluxo e as áreas transversais permite criar ecossistemas de dados sustentáveis e adaptáveis.



Lakehouse e Databricks


Bootcamp Databricks

I&D Capgemini Brasil




Combinação de Data Lakes e Warehouses

Lakehouse une a flexibilidade dos Data Lakes com a governança e desempenho dos Data Warehouses.



Simplificação e Eficiência

Lakehouse reduz complexidade, evita duplicação e melhora a integração entre equipes de dados.



Governança e Segurança

Lakehouse oferece governança, catalogação e segurança para compartilhar dados entre perfis diversos.



Introdução ao Databricks

Plataforma Unificada

Databricks integra engenharia de dados, ciência de dados e IA em uma única plataforma eficiente.

Processamento Distribuído


Utiliza Apache Spark para processamento distribuído, garantindo alto desempenho e escalabilidade.

Governança e Segurança

Inclui controle e governança de dados com Unity Catalog para segurança e conformidade.


Colaboração e Automação

Oferece notebooks colaborativos e workflows automatizados para acelerar o desenvolvimento.





Componentes Principais da Plataforma



Ambiente de Desenvolvimento

Notebooks fornecem um ambiente colaborativo para executar código em Python, SQL e outras linguagens.

Processamento Escalável

O mecanismo de Compute oferece recursos escaláveis para executar workloads de forma eficiente.

Armazenamento Confiável

Delta Lake fornece uma camada transacional para armazenamento robusto e operações avançadas sobre dados.

Governança e Automação

Unity Catalog gerencia metadados e acessos, enquanto Jobs automatizam e orquestram processos.

Atividades práticas

Bootcamp Databricks

I&D Capgemini Brasil

Bootcamp Databricks

Laboratório Dia 1

Onboarding + Workspace + Unity Catalog + Medallion + Primeiro Dataset

Objetivo:

Ao final deste laboratório, você será capaz de configurar seu ambiente Databricks, navegar pelos principais recursos da plataforma, estruturar um Lakehouse utilizando Unity Catalog e arquitetura Medallion, além de carregar, consultar e validar dados reais utilizando notebooks e tabelas Delta.

Jornada do laboratório

Sequência recomendada para todos os alunos concluírem o Dia 1 com a mesma base técnica.

1



Conta grátis

Cadastrar na Databricks Free Edition e acessar o workspace.

2



Tour da plataforma

Identificar Workspace, Catalog, Compute, SQL Editor e Workflows.

3



Catálogo

Criar catálogo [capgemini_academy]. Apagar schema [default]

4



Schemas

Criar [bronze], [silver] e [gold] como base da arquitetura Medallion. E [sandbox] + [landing] para outras finalidades.

5



Volume landing

Criar [landing.files] para receber arquivos brutos diversos.

6



GitHub apoio

Consultar exemplos SQL, PySpark e DataFrame nos repositórios indicados.

7



MovieLens

Baixar MovieLens Small, subir CSVs no volume e validar leitura.

Estrutura esperada

Catálogo individual no Unity Catalog

capgemini_academy

BRONZE

landing

movies, ratings

SILVER

limpeza

próximos labs

GOLD

consumo

próximos labs

Checklist do aluno

- ✓ Conta criada e workspace acessível
- ✓ Menus principais identificados
- ✓ Catálogo e schemas criados
- ✓ Volume bronze.landing criado
- ✓ MovieLens Small enviado

Desafio: criar bronze.ratings e executar SELECT COUNT(*)

Comandos essenciais

```
CREATE CATALOG capgemini_academy;  
CREATE SCHEMA capgemini_academy.bronze;  
CREATE SCHEMA capgemini_academy.silver;  
CREATE SCHEMA capgemini_academy.gold;  
CREATE VOLUME capgemini_academy.landing.files;
```

```
SELECT COUNT(*)  
FROM capgemini_academy.bronze.ratings;
```

Dados contam histórias. Engenheiros de Dados constroem o caminho para ouvi-las.



Demonstração e Navegação na Plataforma

Familiarização com Interface

Introdução ao workspace, notebooks e catálogo de dados para melhorar a experiência inicial do usuário.

Conceitos Básicos de Navegação

Aprender a localizar artefatos, criar objetos e acessar funcionalidades essenciais para desenvolvimento.

Execução e Organização

Demonstração de execução de notebooks, organização de pastas e gerenciamento de recursos computacionais.

Preparação para Laboratórios Futuros

Objetivo de aumentar a confiança dos alunos e facilitar o uso da plataforma em atividades futuras.





Laboratório Inicial e Encerramento

Laboratório Prático Inicial

Criar notebooks e executar comandos básicos em Python e SQL para familiarização com a plataforma.

Integração Multilínguas na Plataforma


A plataforma suporta múltiplas linguagens, permitindo uso integrado de código e documentação em células Markdown.

Resumo e Conceitos Fundamentais

Encerramento destaca conceitos como Engenharia de Dados, ciclo de vida dos dados e arquitetura Lakehouse.

Próximos Passos no Treinamento

Apresentação dos tópicos futuros como SQL, tabelas Delta Lake e operações de armazenamento.





Referências

- Databricks BR

<https://github.com/Databricks-BR>

- Spark The Definitive Guide

<https://github.com/databricks/Spark-The-Definitive-Guide>

- Kaggle

www.kaggle.com

- Grouplens

<https://grouplens.org/>



Desafio do Dia 1 – Assistir e resumir

- O que é Databricks

https://www.youtube.com/watch?v=X5zTCgPN_D4&list=LL&index=3

- Roadmap Engenheiro de Dados

<https://www.youtube.com/watch?v=klk8tj0rbo0&list=LL&index=2>

Thank you.

Make it real.

Capgemini 