

Bootcamp Databricks

Engenharia de Dados dentro da Plataforma Data & AI

I&D Capgemini Brasil, Setembro/2026


Agenda

Aulas	Assunto
Dia 1 – 14/09/2026	Fundamentos de Engenharia de dados e Databricks
Dia 2 – 15/09/2026	SQL, bancos, tabelas e Delta Lake
Dia 3 – 16/09/2026	Unity Catalog, schemas, volumes e governança
Dia 4 – 17/09/2026	Ingestão de dados: Batch, Incremental, Auto Loader
Dia 5 – 18/09/2026	ETL vs ELT & transformação arquitetura medalhão
Dia 6 – 21/09/2026	Modelagem de dados para Analytics
Dia 7 – 22/09/2026	Processamento distribuído com Spark no Databricks
Dia 8 – 23/09/2026	Streaming e processamento contínuo
Dia 9 – 24/09/2026	Orquestração, Jobs, DataOps e boas práticas
Dia 10 – 25/09/2026	Qualidade, observabilidade, arquitetura e desafio final

Dia 6 - Modelagem de dados para Analytics

Do Gold Layer ao modelo dimensional para Analytics

I&D Capgemini Brasil, Setembro/2026



ÚNICA FONTE
DA VERDADE

CONFIANÇA
E GOVERNANÇA

DESEMPENHO
E ESCALABILIDADE

ANÁLISE PARA
TOMADA DE DECISÃO

Fundamentos de Modelagem Analítica



Objetivos

Criar o modelo mental antes de desenhar tabelas.

- Explicar por que modelagem ainda importa no Lakehouse.
- Diferenciar workloads transacionais e analíticos.
- Comparar modelo transacional e modelo analítico.
- Entender fatos, dimensões, medidas, atributos e granularidade.

Mensagem central

Boa modelagem reduz complexidade, melhora entendimento e cria confiança no consumo analítico.

Entregável conceitual

O aluno deve sair sabendo dizer o que é fato, dimensão, medida, atributo e granularidade.



Por que modelagem ainda importa no Lakehouse?

Gold não é apenas tabela agregada. Gold é contrato de consumo.

Clareza

Usuários entendem onde buscar métricas e filtros.

Consistência

Métricas são definidas uma vez e reutilizadas.

Performance

Modelos analíticos reduzem leitura e joins desnecessários.

- Sem modelagem, cada dashboard pode reinventar a mesma métrica.
- Sem granularidade clara, a mesma tabela pode gerar números diferentes.
- Sem dimensões bem definidas, filtros e agrupamentos ficam ambíguos.
- Modelagem transforma dados Gold em produto analítico reutilizável.



Modelo transacional vs Modelo analítico

O mesmo negócio pode ter desenhos diferentes para finalidades diferentes.

Modelo transacional

Prioriza integridade operacional, baixa redundância e escrita eficiente. Normalmente exige muitas tabelas e relações para representar a operação.

Modelo analítico

Prioriza leitura, entendimento e agregação. Organiza eventos e contexto para responder perguntas de negócio.

Pergunta analítica:

Quanto vendemos por mês, produto, cliente e região?

Resposta modelada:


```
fact_sales + dim_date + dim_product + dim_customer + dim_geography
```

Fato x Dimensão

Fatos registram o que aconteceu; dimensões descrevem o contexto.

★ STAR SCHEMA ★

Modelo Dimensional para Analytics



Primary Key (PK)

Identifica unicamente cada registro na dimensão.



Foreign Key (FK)

Chave na tabela fato que referencia as dimensões.



Measures

Valores numéricos que são agregados e analisados.



Benefícios do Star Schema

- ✓ Simplicidade e fácil entendimento
- ✓ Consultas rápidas e performance
- ✓ Ideal para BI e análises multidimensionais
- ✓ Consistência de métricas e KPIs



Medidas, atributos e granularidade

Granularidade é a decisão que governa todas as outras.

Medidas

Valores numéricos agregáveis:
quantidade, receita, custo,
margem.

Atributos

Descrições usadas para filtrar,
agrupar e segmentar análises.

Granularidade

O que exatamente uma linha
representa na tabela fato.

- Exemplo de granularidade: uma linha por pedido, por item de pedido, por dia/produto ou por cliente/mês.
- Se a granularidade não está clara, a métrica nunca será confiável.
- A granularidade deve ser definida antes das chaves e antes das agregações.



Exercício conceitual

Item	Classificação
data_pedido	Dimensão / atributo de tempo
cliente_nome	Dimensão / atributo de cliente
produto_categoria	Dimensão / atributo de produto
quantidade	Medida
valor_venda	Medida
order_id	Identificador / chave de evento
uma linha por item de pedido	Granularidade

Star Schema

Modelo Estrela para Analytics

Fato x Dimensão: Visão Conceitual

Modelo dimensional (estrela): fatos como transações e medidas numéricas, dimensões como contexto descritivo, conectados por chaves.



DIMENSÃO: TEMPO	
Atributo	Exemplo
data	01/05/2025
dia_da_semana	Quinta-feira
mes	Maio
trimestre	2
ano	2025
Hierarquia: Dia > Mês > Trimestre > Ano	

DIMENSÃO: CLIENTE	
Atributo	Exemplo
cliente	Ana Silva
genero	Feminino
faixa_etaria	25-34
cidade	São Paulo
estado	SP
Hierarquia: Cliente > Cidade > Estado > País	

DIMENSÃO: PRODUTO	
Atributo	Exemplo
produto	Tênis Runner
categoria	Calçados
marca	Acme
subcategoria	Esportivo
Hierarquia: Produto > Subcategoria > Categoria	

FATOS
Transações / Eventos
Medidas numéricas
O que aconteceu?

DIMENSÕES
Contexto descritivo
Atributos e hierarquias
Quem? O quê? Quando? Onde? Como?

FATO: VENDAS			
	Coluna	Descrição	Exemplo
CHAVES	tempo_key	Chave da dimensão Tempo	20250501
	cliente_key	Chave da dimensão Cliente	100235
	produto_key	Chave da dimensão Produto	200542
	loja_key	Chave da dimensão Loja	30012
	canal_key	Chave da dimensão Canal	40003
MEDIDAS	quantidade	Quantidade vendida	3
	valor_venda	Valor bruto da venda	259.90
	custo	Custo dos produtos	152.40
	margem	Margem da venda	107.50

DIMENSÃO: LOJA	
Atributo	Exemplo
loja	Loja SP Centro
cidade	São Paulo
estado	SP
regiao	Sudeste
pais	Brasil
Hierarquia: Loja > Cidade > Estado > Região > País	

DIMENSÃO: CANAL	
Atributo	Exemplo
canal	E-commerce
tipo_canal	Digital
plataforma	Site
origem	Orgânico
Hierarquia: Canal > Tipo > Plataforma > Origem	

 Chave (Relacionamento)
Liga as dimensões ao fato



Consultas rápidas
Estrutura otimizada para análise.



Consistência
Métricas definidas uma única vez.



Governança
Dados padronizados, confiáveis e auditáveis.



Flexibilidade
Análises por múltiplas perspectivas.



Escalável
Pronto para crescer com o seu negócio.



Introdução ao Star Schema

Um desenho simples para responder perguntas analíticas com clareza.

- Star Schema é uma técnica de modelagem dimensional adotada em data warehouses relacionais.
- O desenho tem uma tabela fato no centro e tabelas dimensão como os pontos da estrela.
- A proposta é otimizar consultas analíticas com filtros, agrupamentos e sumarizações.
- No contexto do curso, a Gold vira base para um Data Mart dimensional.

Mensagem central

Não basta ter uma Gold. Para Analytics, a Gold precisa ser compreensível, reutilizável e consistente.

Resultado esperado

O aluno sabe explicar por que fatos e dimensões formam um modelo estrela.



Estrutura de uma tabela Fato

Tabela fato guarda eventos, chaves das dimensões e medidas agregáveis.

Evento

Uma linha representa uma observação ou evento em uma granularidade definida.

Chaves

Contém chaves que conectam o fato às dimensões.

Medidas

Guarda valores numéricos que podem ser agregados.

`fact_sales`

- `date_key`
- `product_key`
- `customer_key`
- `geography_key`
- `quantity`
- `sales_amount`
- `discount_amount`
- `order_count`

- A tabela fato deve ter granularidade declarada.
- Se a granularidade muda, a interpretação das métricas muda.
- Medidas precisam ter unidade, regra e possibilidade de agregação claras.



Estrutura de uma tabela Dimensão

Dimensão descreve o contexto usado para filtrar, agrupar e explicar fatos.

Identificador

Chave da dimensão e, quando necessário, chave natural do sistema de origem.

Atributos

Características descritivas: nome, categoria, segmento, cidade, região.

Hierarquias

Caminhos de análise: produto > categoria > marca, data > mês > ano.

```
dim_product
```

```
- product_key  
- product_id  
- product_name  
- category  
- subcategory  
- brand
```

- Dimensões ajudam o usuário a perguntar “por quem, por onde, por quando e por qual produto”.
- Bons atributos de dimensão reduzem necessidade de joins improvisados no BI.
- Dimensão bem nomeada é documentação viva do modelo



Dimensão Produto

Dimensão Produto responde “o que foi vendido?”

Chave

product_key como identificador no modelo analítico.

Chave natural

product_id preserva referência ao sistema de origem.

Atributos

Nome, categoria, subcategoria, marca e status.

dim_product

product_key	INT
product_id	STRING
product_name	STRING
category	STRING
subcategory	STRING
brand	STRING

- A dimensão Produto costuma sustentar análises por categoria, marca, linha e hierarquia comercial.
- Evite colocar métricas transacionais dentro da dimensão Produto.
- Se atributos mudam historicamente, discutiremos SCD conceitualmente.



Dimensão Cliente

Dimensão Cliente responde “quem comprou?” ou “qual segmento consumiu?”

Chave

customer_key como identificador analítico.

Atributos

Nome, segmento, cidade, país, faixa ou classificação.

Cuidados

Privacidade, minimização e necessidade real de atributos.

dim_customer

customer_key	INT
customer_id	STRING
customer_name	STRING
segment	STRING
city	STRING
country	STRING

- Nem todo atributo de cliente deve ir para consumo analítico.
- Atributos sensíveis exigem governança e justificativa.



Dimensão Data

Dimensão Data é pequena, mas central para quase todo modelo analítico.

Chave

date_key ou full_date para ligação com fatos.

Atributos

Dia, mês, trimestre, ano, nome do mês, dia da semana.

Uso

Filtros e hierarquias temporais em dashboards.

```
dim_date
date_key      INT
full_date     DATE
day           INT
month         INT
quarter       INT
year          INT
day_name      STRING
```

- Dimensão Data evita repetir lógica de calendário em múltiplos dashboards.
- Permite padronizar hierarquias temporais.
- Pode incorporar calendário fiscal quando necessário.



Benefícios e limitações do Star Schema

Use star schema quando o objetivo é consumo analítico claro e reutilizável.

Benefício 1

Modelo simples para usuários e ferramentas de BI.

Benefício 2

Consultas analíticas com filtros, agrupamentos e sumarizações.

Benefício 3

Base consistente para métricas e modelos semânticos.

- Limitação: não é a melhor forma de representar todos os detalhes operacionais.
- Limitação: mudanças históricas em dimensões exigem estratégia de SCD.
- Limitação: se a granularidade for mal definida, o modelo continua gerando confusão.
- Próxima parte: modelagem no Databricks, surrogate keys, Delta Lake e SCD.

Modelagem no Databricks

Gold Layer como Data Mart, surrogate keys, Delta Lake e SCD





Gold Layer como Data Mart

No Lakehouse, a Gold pode ser organizada para consumo analítico direto.

Gold agregada

Tabelas com métricas prontas para consumo.

Data Mart

Recorte orientado a domínio, como vendas, financeiro ou clientes.

Modelo dimensional

Fatos e dimensões com regras explícitas de consumo.

- O Data Mart simplifica o acesso de BI e analytics.
- A Gold pode ser uma tabela agregada simples ou um modelo dimensional completo.
- A decisão depende do público, da granularidade e da reutilização esperada.
- Para o treinamento, vamos evoluir a Gold em um Data Mart de vendas.



Construindo dimensões a partir da Bronze

Dimensões nascem dos atributos descritivos que serão reutilizados em análises.

```
CREATE OR REPLACE TABLE gold.dim_movies AS
SELECT DISTINCT
  movieId,
  title,
  genres
FROM bronze.movies
WHERE movieId IS NOT NULL;
```

- Use DISTINCT para obter os membros únicos da dimensão.
- Separe atributos descritivos de medidas transacionais.
- Documente a origem de cada atributo.
- Valide duplicidades na chave natural antes de publicar.

Regra prática

Se um campo serve para filtrar, agrupar ou explicar um fato, provavelmente pertence a uma dimensão.



Construindo a tabela Fato

A fato materializa o evento na granularidade correta e referencia dimensões.

```
CREATE OR REPLACE TABLE gold.fact_sales AS
SELECT
    d.date_key,
    p.product_key,
    c.customer_key,
    s.order_id,
    s.quantity,
    s.order_value AS sales_amount
FROM bronze.sales AS s
JOIN gold.dim_date AS d
    ON s.order_date = d.full_date
JOIN gold.dim_product AS p
    ON s.product_id = p.product_id
JOIN gold.dim_customer AS c
    ON s.customer_id = c.customer_id;
```

- A fato carrega chaves dimensionais e medidas.
- A granularidade precisa estar documentada no notebook e no comentário da tabela.
- Uma fato de vendas por item de pedido não é igual a uma fato agregada por dia/produto.
- Faça contagens antes e depois dos joins para evitar perda silenciosa de linhas.



Estratégias de surrogate keys

Surrogate key é uma chave técnica do modelo, separada da chave natural do sistema de origem.

Natural key

Identificador vindo da origem, como product_id ou customer_id.

Surrogate key

Identificador técnico criado no modelo analítico, como product_key.

Por quê?

Ajuda a controlar histórico, padronização e integração entre fontes.

```
CREATE OR REPLACE TABLE gold.dim_product AS
SELECT
    row_number() OVER (ORDER BY product_id) AS product_key,
    product_id, product_name, category, brand
FROM (
    SELECT DISTINCT product_id, product_name, category, brand
    FROM bronze.products
);
```



Delta Lake para dimensões

Dimensão também é tabela operacionalmente gerenciada, não apenas desenho lógico.

ACID

Transações confiáveis para alterações controladas.

Histórico

Possibilidade de raciocinar sobre versões quando aplicável.

MERGE

Base para upsert em dimensões e manutenção incremental.

- Delta Lake ajuda a tratar dimensões como contratos de dados persistidos.
- Use comentários, nomes qualificados e governança via Unity Catalog.
- Evite recriar dimensões sem entender impacto nos fatos e dashboards.
- A estratégia de carga da dimensão deve ser compatível com SCD Type 1 ou Type 2 quando houver mudanças.



Slowly Changing Dimensions (SCD)

SCD define como a dimensão reage quando atributos mudam ao longo do tempo.

Mudança comum

Cliente muda de cidade, produto muda de categoria ou canal muda de descrição.

Decisão chave

Manter somente o valor atual ou preservar histórico?

Impacto

A decisão afeta relatórios históricos, joins e rastreabilidade.

- SCD Type 1 sobrescreve valores antigos com novos valores.
- SCD Type 2 cria nova versão do registro para acompanhar mudanças no tempo.



SCD Type 1

Sobrescreve o valor anterior e mantém apenas a visão atual.

Quando usar

Correções ou atributos em que histórico não é necessário.

Vantagem

Mais simples de consultar e manter.

Limitação

Perde a versão anterior do atributo.

```
MERGE INTO gold.dim_product AS t
USING bronze.products AS s
ON t.product_id = s.product_id
WHEN MATCHED THEN UPDATE SET
    t.product_name = s.product_name,
    t.category = s.category,
    t.brand = s.brand
WHEN NOT MATCHED THEN INSERT *;
```



SCD Type 2 e boas práticas

Preserva histórico criando novas versões de registros dimensionais.

Quando usar

Quando o histórico do atributo afeta análises e relatórios.

Como pensar

Fechar versão antiga e abrir nova versão vigente.

Campos comuns

effective_start, effective_end e is_current.

- Defina quais atributos precisam de histórico antes de implementar.
- Evite SCD Type 2 para todos os campos sem necessidade real.
- Valide se somente uma versão está vigente por chave natural.
- Documente a regra de join entre fato e dimensão quando usar histórico.
- Próxima parte: laboratório para construir Data Mart com fato e dimensões.

Laboratório Hands-On

Mini Data Mart no Databricks



Nível: Intermediário



Duração: ~90 minutos



Público: Eng. de Dados



Tecnologias: Databricks, SQL, Delta Lake, Unity Catalog

OBJETIVO DO LAB

Transformar os dados da camada Gold em um mini data mart no formato dimensional (Star Schema), criando **fact_sales** e as dimensões **dim_date**, **dim_product** e **dim_customer**, consolidando métricas para consumo analítico.



1 VISÃO GERAL DA ARQUITETURA

Vamos construir um mini data mart na camada GOLD seguindo um modelo dimensional em estrela (Star Schema).



FLUXO DE DADOS



2 FONTE DE DADOS (GOLD)

Utilizaremos a tabela Gold de vendas consolidada (exemplo):

```
SELECT * FROM analytics.gold.sales_enriched LIMIT 5;
```

order_id	order_date	customer_id	customer_name	product_id	product_name	quantity	unit_price	discount_pct	sales_amount	channel_id
1001	2024-01-01	C001	Ana Silva	P100	Smartphone X	1	1999.00	0.05	1899.05	ONL
1002	2024-01-01	C002	Bruno Costa	P200	Fone Bluetooth	2	299.90	0.10	539.82	STOR
1003	2024-01-02	C001	Ana Silva	P300	Smartwatch Z	1	899.00	0.00	899.00	ONL
1004	2024-01-02	C003	Carla Lima	P100	Smartphone X	1	1999.00	0.07	1859.07	ONL
1005	2024-01-03	C004	Diego Souza	P200	Fone Bluetooth	1	299.90	0.00	299.90	MARKET

Obs.: Ajuste os nomes de colunas conforme o seu modelo de Gold.

3 MODELO DIMENSIONAL – DEFINIÇÕES

dim_date

```
CREATE TABLE analytics.gold.dim_date (
  date_key INT PRIMARY KEY,
  full_date DATE,
  day INT,
  day_name STRING,
  week_of_year INT,
  month INT,
  month_name STRING,
  quarter INT,
  year INT,
  is_weekend INT,
) USING DELTA
COMMENT "Dimensão de datas";
```

dim_product

```
CREATE TABLE analytics.gold.dim_product (
  product_key INT,
  product_id STRING,
  product_name STRING,
  category STRING,
  subcategory STRING,
  brand STRING,
) USING DELTA
COMMENT "Dimensão de produtos";
```

dim_customer


```
CREATE TABLE analytics.gold.dim_customer (
  customer_key INT,
  customer_id STRING,
  first_name STRING,
  last_name STRING,
  email STRING,
  city STRING,
  state STRING,
  country STRING,
  customer STRING,
) USING DELTA
COMMENT "Dimensão de clientes";
```

fact_sales

```
CREATE TABLE analytics.gold.fact_sales (
  sales_key BIGINT GENERATED ALWAYS AS IDENTITY,
  date_key INT,
  customer_key INT,
  product_key INT,
  quantity INT,
  unit_price DECIMAL(12,2),
  discount_amount DECIMAL(12,2),
  tax_amount DECIMAL(12,2),
  shipping_amount DECIMAL(12,2),
  sales_amount DECIMAL(12,2),
  order_count INT,
) USING DELTA
COMMENT "Fato de vendas";
```

Boas práticas: use chaves substitutas (surrogate keys) nas dimensões e mantenha chaves naturais (NK) para rastreabilidade.

6 PASSO A PASSO DO DATA MART (STAR SCHEMA)



4 SQL NOTEBOOK – CONSTRUÇÃO DO MODELO

1. Popular dim_date

```
INSERT INTO analytics.gold.dim_date
SELECT DISTINCT
  CAST(date_format(order_date, 'yyyyMMdd') AS INT) AS date_key,
  CAST(order_date AS DATE) AS full_date,
  DAY(order_date) AS day,
  DATE_FORMAT(order_date, 'EEEE') AS day_name,
  WEEKOFYEAR(order_date) AS week,
  MONTH(order_date) AS month,
  DATE_FORMAT(order_date, 'MMMM') AS month_name,
  QUARTER(order_date) AS quarter,
  YEAR(order_date) AS year,
  DAYOFWEEK(order_date) IN (1,7) AS is_weekend
FROM analytics.gold.sales_enriched;
```

2. Popular dim_product

```
INSERT INTO analytics.gold.dim_product (product_key, product_id,
product_name, category, subcategory, brand)
SELECT
  monotonically_increasing_id() + 1 AS product_key,
  product_id, product_name, category, subcategory, brand
FROM analytics.gold.sales_enriched
GROUP BY product_id, product_name, category, subcategory, brand;
```

3. Popular dim_customer

```
INSERT INTO analytics.gold.dim_customer (customer_key, customer_id,
first_name, last_name, email, city, state, country, customer_segment)
SELECT
  monotonically_increasing_id() + 1 AS customer_key,
  customer_id, first_name, last_name, email, city, state, country, customer_segment
FROM analytics.gold.customers_clean;
```

4. Popular dim_channel

```
INSERT INTO analytics.gold.dim_channel (channel_key, channel_id, channel_desc)
VALUES (0, 'UNKNOWN', 'Desconhecido'),
(1, 'ONL', 'Online'),
(2, 'STOR', 'Store Física'),
(3, 'MARKET', 'Marketplace');
```

5. Popular fact_sales

```
INSERT INTO analytics.gold.fact_sales (
  date_key, customer_key, product_key,
  quantity, unit_price, discount_amount, tax_amount,
  shipping_amount, sales_amount, order_count)
SELECT
  d.date_key,
  c.customer_key,
  p.product_key,
  DATE_FORMAT(c.channel_key, 0) AS channel_key,
  s.quantity,
  s.unit_price,
  s.discount_amount,
  s.tax_amount,
  s.shipping_amount,
  s.sales_amount,
  s.order_count
FROM analytics.gold.sales_enriched s
JOIN analytics.gold.dim_date d ON (d.date_key = s.date_key)
JOIN analytics.gold.dim_customer c ON (c.customer_key = s.customer_key)
JOIN analytics.gold.dim_product p ON (p.product_key = s.product_key)
JOIN analytics.gold.dim_channel ch ON (ch.channel_key = s.channel_key);
```

7 BOAS PRÁTICAS

- Use chaves substitutas (surrogate keys) nas dimensões.
- Mantenha chaves naturais (NK) para rastreabilidade.
- Inclua registro "Unknown" nas dimensões (ex.: key = 0).
- Normalize somente se necessário; prefira star schema.
- Particione a fact_sales por date_key (ex.: por mês).
- Comente tabelas e colunas para documentação.
- Valide volumes e integridade após cada carga.
- Utilize Delta Lake para ACID, time travel e performance.

5 VALIDAÇÕES – CHECKLIST

#	Validação	SQL de Verificação	Esperado
1	Dim Date populada?	SELECT COUNT(*) FROM analytics.gold.dim_date;	> 0
2	Dim Product populada?	SELECT COUNT(*) FROM analytics.gold.dim_product;	> 0
3	Dim Customer populada?	SELECT COUNT(*) FROM analytics.gold.dim_customer;	> 0
4	Fact Sales populada?	SELECT COUNT(*) FROM analytics.gold.fact_sales;	> 0
5	Chaves órfãs (Customer)	SELECT COUNT(*) FROM analytics.gold.fact_sales f LEFT ANTI JOIN analytics.gold.dim_customer c ON f.customer_key = c.customer_key;	0
6	Chaves órfãs (Product)	SELECT COUNT(*) FROM analytics.gold.fact_sales f LEFT ANTI JOIN analytics.gold.dim_product p ON f.product_key = p.product_key;	0
7	Chaves órfãs (Date)	SELECT COUNT(*) FROM analytics.gold.fact_sales f LEFT ANTI JOIN analytics.gold.dim_date d ON f.date_key = d.date_key;	0
8	Totais batem? (Faturamento)	SELECT SUM(sales_amount) FROM analytics.gold.fact_sales;	Confere com soma da Silver/Gold

EXEMPLOS DE CONSULTAS ANALÍTICAS

- Receita por Dia**
SELECT d.full_date, SUM(f.sales_amount) AS receita FROM analytics.gold.fact_sales f JOIN analytics.gold.dim_date d ON f.date_key = d.date_key GROUP BY d.full_date ORDER BY d.full_date;
- Top 10 Clientes por Receita**
SELECT c.customer_id, c.first_name, c.last_name, SUM(f.sales_amount) AS receita FROM analytics.gold.fact_sales f JOIN analytics.gold.dim_customer c ON f.customer_key = c.customer_key GROUP BY c.customer_id ORDER BY receita DESC LIMIT 10;
- Receita por Categoria de Produto**
SELECT p.category, SUM(f.sales_amount) AS receita FROM analytics.gold.fact_sales f JOIN analytics.gold.dim_product p ON f.product_key = p.product_key GROUP BY p.category ORDER BY receita DESC;

9 ENTREGÁVEIS DO LAB

- Dimensões criadas e populadas: dim_date, dim_product, dim_customer, dim_channel
- Tabela fato criada e populada: fact_sales
- Zero chaves órfãs (validações OK)
- Consultas analíticas executadas com sucesso
- Notebook documentado com comentários

PRÓXIMO PASSO

Dia 6: Modelagem de Dados para Analytics
Exploraremos outras abordagens (Data Vault, Camadas Semânticas e Métricas Governadas).



Bootcamp Databricks

Laboratório Dia 6

Modelagem dimensional: Star Schema, fatos e dimensões

Objetivo: Transformar as tabelas Silver/Gold dos Dias 5 em um Data Mart dimensional, criando dimensões, tabela fato, chaves dimensionais e consultas analíticas reutilizáveis para BI e Analytics.

Narrativa: no Dia 5 criamos métricas Gold. No Dia 6 organizamos esses dados em um modelo dimensional consumível: fato + dimensões + validações.

Jornada prática do laboratório

1

SRC

Dataset Kaggle

Indian E_Commerce Sales Analytics

2

FACT

Grão da fato

Definir fact_sales com uma linha por pedido/produto e medidas.

3

CLI

Dim Cliente

Criar dim_cliente com customer_key e cliente_id.

4

PROD

Dim Produto

Criar dim_produto com product_key e produto_id.

5

DATE

Dim Data

Criar dim_data com date_key, data, ano e mês.

6

JOIN

Fato Vendas

Montar fact_sales com chaves dimensionais + medidas.

7

QA

Validações

Checar chaves órfãs, contagens e coerência dos totais.

8

BI

Analytics

Consultar receita por período e produto para preparar o Dia 7.

Star Schema esperado

capgemini_academy.gold

DIM DATE

date_key
ano, mes

FACTSALES

customer_key
product_key
order_value

DIM PRODUCT

product_key
product_id

dim_customer também conecta à fato

Gold em modelo

Checklist de validação

- dim_customer, dim_product e dim_date criadas
- fact_sales criada com chaves dimensionais
- Sem cliente/produto/data órfãos
- Totais da fato batem com Silver/Gold
- Consulta analítica executada
- Modelo pronto para PySpark no Dia 7

Comandos centrais (exemplos)

```

CREATE TABLE gold.dim_cliente AS SELECT DISTINCT ...
CREATE TABLE gold.dim_produto AS SELECT DISTINCT ...
CREATE TABLE gold.dim_data AS SELECT DISTINCT ...
CREATE TABLE gold.fact_sales AS SELECT ... JOIN dims
LEFT JOIN dims WHERE dim_key IS NULL -- órfãos
SELECT ano, mes, SUM(valor_total) FROM fact_sales ...

```

Modelagem reduz ambiguidade e melhora consumo analítico.



Fonte de dados Gold

Vamos partir de uma bronze produzida no Dia 5 (Indian E-Commerce Sales Analytics).

Origem

capgemini_academy.bronze.sales ou
tabela equivalente do seu lab.

Objetivo

Transformar uma tabela bronze
ampla em modelo estrela.

Resultado

Mini Data Mart com fato e
dimensões reutilizáveis.

```
SELECT *  
FROM capgemini_academy.bronze.sales  
LIMIT 10;  
  
-- Verificar colunas esperadas  
DESCRIBE TABLE capgemini_academy.bronze.sales;
```

- Ajuste nomes de catálogo, schema e tabela conforme o ambiente do treinamento.
- Antes de modelar, valide colunas, tipos, volume e exemplo de registros.



Criando dim_date

Dimensão Data padroniza calendário e evita lógica duplicada em dashboards.

```
CREATE OR REPLACE TABLE
capgemini_academy.gold.dim_date AS
SELECT DISTINCT
    CAST(date_format(Order_Date, 'yyyyMMdd') AS INT)
    AS date_key,
    Order_Date AS full_date,
    day(Order_Date) AS day,
    month(Order_Date) AS month,
    quarter(Order_Date) AS quarter,
    year(Order_Date) AS year,
    date_format(Order_Date, 'EEEE') AS day_name
FROM capgemini_academy.bronze.sales
WHERE Order_Date IS NOT NULL;
```

- Use a data real do evento, não a data de carga, para análises de negócio.
- Inclua atributos temporais que serão usados em filtros e hierarquias.
- Valide se full_date é única na dimensão.

Validação

```
SELECT date_key, COUNT(*) FROM gold.dim_date
GROUP BY date_key HAVING COUNT(*) > 1
```



Criando dim_product

Produto é uma das dimensões mais usadas para análise comercial.

```
CREATE OR REPLACE TABLE
capgemini_academy.gold.dim_product AS
SELECT
    row_number() OVER (ORDER BY product_id) AS product_key,
    product_id,
    product_name,
    category,
    brand
FROM (
    SELECT DISTINCT Product_ID, Product_Name, Category,
    Brand
    FROM capgemini_academy.bronze.products
    WHERE Product_ID IS NOT NULL
);
```

- Product_Key é a surrogate key do modelo analítico.
- Product_ID preserva a chave natural da fonte.
- Atributos descritivos devem ser usados para segmentação e filtro.
- Não armazene métricas de venda na dimensão Produto.

Validação

product_id deve identificar um único membro da dimensão.



Criando dim_customer

Cliente contextualiza consumo, segmento e localização.

```
CREATE OR REPLACE TABLE
capgemini_academy.gold.dim_customer AS
SELECT
    row_number() OVER (ORDER BY Customer_ID) AS
customer_key,
    customer_id,
    customer_name,
    gender,
    city,
    state
FROM (
    SELECT DISTINCT Customer_ID, Customer_Name, Gender,
City, State
    FROM capgemini_academy.bronze.customers
    WHERE Customer_ID IS NOT NULL
);
```

- Use somente atributos necessários ao consumo analítico do laboratório.
- Evite atributos sensíveis se não forem necessários.
- Valide duplicidades na chave natural.
- Se o cliente mudar de cidade ou estado, o tratamento histórico será tema de SCD.

Validação

customer_id deve ter cardinalidade compatível com a dimensão.



Criando fact_sales

A fato conecta dimensões e concentra medidas na granularidade definida.

```
CREATE OR REPLACE TABLE capgemini_academy.gold.fact_sales AS
SELECT
    d.date_key,
    p.product_key,
    c.customer_key,
    s.order_id,
    s.quantity,
    s.unit_price,
    s.order_value
FROM capgemini_academy.bronze.sales AS s
JOIN capgemini_academy.gold.dim_date AS d ON s.order_date =
d.full_date
JOIN capgemini_academy.gold_dim_product AS p ON s.product_id
= p.product_id
JOIN capgemini_academy.gold_dim_customer AS c ON
s.customer_id = c.customer_id;
```

- Defina a granularidade: uma linha por item de pedido.
- A fato deve conter chaves das dimensões e medidas agregáveis.
- Evite carregar atributos descritivos redundantes na fato.
- Valide linhas perdidas por joins internos.

Cuidado

Se houver perda de linhas, investigue dimensões incompletas.



Validações do Data Mart

Um modelo só está pronto quando passa por validações objetivas.

Validação	SQL de Referência	Esperado
Dim Date populada	SELECT COUNT(*) FROM capgemini_academy.gold.dim_date	>0
Dim Product populada	SELECT COUNT(*) FROM capgemini_academy.gold.dim_product	>0
Dim Customer populada	SELECT COUNT(*) FROM capgemini_academy.gold.dim_customer	>0
Fact Sales populada	SELECT COUNT(*) FROM capgemini_academy.gold.fact_sales	>0
Chaves órfãs	LEFT ANTI JOIN fato x dimensão	0
Totais batem	Comparar soma Silver/Gold x fato	Sem divergência



Consultas analíticas

O objetivo do modelo é facilitar perguntas de negócio.

```
-- Receita por mês e categoria
SELECT
  d.year, d.month, p.category,
  SUM(f.order_value) AS revenue
FROM capgemini_academy.gold.fact_sales AS f
JOIN capgemini_academy.gold.dim_date AS d ON f.date_key = d.date_key
JOIN capgemini_academy.gold.dim_product AS p ON f.product_key = p.product_key
GROUP BY d.year, d.month, p.category
ORDER BY d.year, d.month, revenue DESC;

-- Top clientes por receita
SELECT c.customer_segment, SUM(f.order_value) AS revenue
FROM capgemini_academy.gold.fact_sales AS f
JOIN capgemini_academy.gold.dim_customer AS c ON f.customer_key = c.customer_key
GROUP BY c.customer_segment
ORDER BY revenue DESC;
```

Mensagem

Se a consulta ficou mais simples, o modelo começou a cumprir seu papel.



Checklist do laboratório

Critérios de aceite para fechar o Day 6.

Item	Status Esperado
Fonte Gold validada	sales_enriched ou equivalente conferida
dim_date criada	Sem duplicidade de date_key
dim_product criada	product_key e product_id disponíveis
dim_customer criada	customer_key e customer_id disponíveis
fact_sales criada	Chaves dimensionais + medidas
Validações executadas	Sem chaves órfãs e com totais coerentes
Consultas analíticas	Receita por período/categoria e segmento executadas



Fechamento e ponte para o Day 7

O Day 6 transforma Gold em modelo dimensional consumível.

Concluído

Mini Data Mart com fato e dimensões.

Aprendizado

Modelagem reduz ambiguidade e melhora consumo analítico.

Próximo

Avançar para orquestração, qualidade ou operação da plataforma.

- Fatos representam eventos e medidas.
- Dimensões representam contexto e filtros.
- Star Schema organiza a Gold para consumo de BI e Analytics.
- O próximo módulo pode evoluir o pipeline para qualidade, jobs e operação.



Desafio do Dia 6 – Assistir e resumir

- Learn Data Modeling in 8 minutes
<https://www.youtube.com/watch?v=WDwNow61JVE>
- BI Data Modeling Explained: Star Schema, Snowflake & Galaxy
- <https://www.youtube.com/watch?v=TtxfKle0HuQ>

Thank you.

Make it real.

Capgemini 