

Bootcamp Databricks

Engenharia de Dados dentro da Plataforma Data & AI

I&D Capgemini Brasil, Setembro/2026

Agenda

Aulas	Assunto
Dia 1 – 14/09/2026	Fundamentos de Engenharia de dados e Databricks
Dia 2 – 15/09/2026	SQL, bancos, tabelas e Delta Lake
Dia 3 – 16/09/2026	Unity Catalog, schemas, volumes e governança
Dia 4 – 17/09/2026	Ingestão de dados: Batch, Incremental, Auto Loader
Dia 5 – 18/09/2026	ETL vs ELT & transformação arquitetura medalhão
Dia 6 – 21/09/2026	Modelagem de dados para Analytics
Dia 7 – 22/09/2026	Processamento distribuído com Spark no Databricks
Dia 8 – 23/09/2026	Streaming e processamento contínuo
Dia 9 – 24/09/2026	Orquestração, Jobs, DataOps e boas práticas
Dia 10 – 25/09/2026	Qualidade, observabilidade, arquitetura e desafio final

Dia 10 - Qualidade, observabilidade, arquitetura final e desafio integrador

Bootcamp Databricks

I&D Capgemini Brasil, Setembro/2026



HANDS-ON INTEGRATED CHALLENGE

FINAL MINI PROJECT

CONSTRUA UM PIPELINE LAKEHOUSE COMPLETO, CONFIÁVEL E OPERÁVEL



CONFIÁVEL
E IDEMPOTENTE



ESCALÁVEL
E ELÁSTICO



OBSERVÁVEL
E MONITORADO



GOVERNADO
E AUDITÁVEL

 **O DESAFIO FINAL**

Seu time deverá entregar um pipeline end-to-end no Databricks Lakehouse, desde a ingestão até a publicação para consumo analítico, com qualidade, orquestração, monitoramento e apresentação final.

 **SEU TIME**



Data Engineer
Pipelines e Transformações



Data Quality Engineer
Regras e Testes



DevOps / DataOps Engineer
Jobs, CI/CD e Infra



Data Analyst
Consumo e Métricas



Tech Lead
Arquitetura e Governança

ENTREGA DO PROJETO

- ✓ Pipeline completo e funcional
- ✓ Jobs orquestrados e monitorados
- ✓ Quality checks com expectativas
- ✓ Dados publicados na camada Gold
- ✓ Dashboards e métricas de negócio
- ✓ Apresentação final (10 minutos)

 **OBJETIVO**

Dados confiáveis e de valor contínuo, gerando insights em tempo real e em batch.



QUALIDADE DE DADOS (EXPECTATIONS)

```
CREATE STREAMING TABLE silver_orders
EXPECT (order_id IS NOT NULL) ON VIOLATION DROP ROW
EXPECT (amount > 0) ON VIOLATION FAIL UPDATE
EXPECT (order_date IS NOT NULL) ON VIOLATION DROP ROW
AS
SELECT * FROM bronze_orders;
```

Taxa de Sucesso: 98% **ok**

Linhas Processadas: 1.2 M

Falhas: 12

Linhas Inválidas: 4.3 K

Validações Contínuas

Quarentena de Inválidos

Gates de Qualidade

MONITORAMENTO & OBSERVABILIDADE

Jobs UI

Spark UI

Logs

Métricas

Alertas

Dashboards

Notificações

Lineagem

SAÚDE DO PIPELINE

Jobs: **Ok**

Qualidade: **Ok**

Dados: **Ok**

Disponibilidade: **Ok**

APRESENTAÇÃO FINAL



10 MINUTOS

- O problema e a solução
- Arquitetura e decisões
- Demonstração do pipeline
- Qualidade e confiabilidade
- Insights gerados
- Lições aprendidas



PRINCÍPIOS DATAOPS

- Automatização ponta a ponta
- Colaboração entre times
- Qualidade integrada ao fluxo
- Pipelines observáveis e confiáveis
- Documentação e runbooks
- Entrega contínua de valor

BOAS PRÁTICAS ESSENCIAIS



Idempotência sempre



Particionamento adequado



Parâmetros, não hardcode



Checkpoint para streaming



Separação por ambiente



Reutilização e modularidade



Monitoramento contínuo



Custo consciente e performance



Segurança por padrão

Objetivos do Dia 10

Fechar a trilha consolidando qualidade, observabilidade, governança e arquitetura enterprise.

- Consolidar conceitos de qualidade de dados.
- Explicar os cinco pilares de observabilidade aplicados a dados.
- Revisar governança, lineage e impacto de mudanças.
- Conectar Lakehouse, Analytics e IA em uma arquitetura final.
- Executar um desafio integrador com ingestão, transformação, publicação, job e qualidade.

Mensagem central

O pipeline só está pronto quando é confiável, governado, observável e demonstrável.

Entregável

Mini projeto final de engenharia de dados no Databricks.

Qualidade: de “funcionou” para “é confiável”

A arquitetura só entrega valor quando os consumidores confiam no dado publicado.

Prevenir

Bloquear ou isolar problemas antes da Gold.

Detectar

Medir nulos, duplicidades, schema, volume e frescor.

Responder

Alertar, corrigir, reprocessar e documentar causa.

- Qualidade precisa estar dentro do pipeline, não apenas em validações manuais.
- Checks devem falar a linguagem do negócio: regra, impacto e ação.
- A qualidade da Gold é consequência de decisões tomadas desde Landing e Bronze.

Dimensões práticas de qualidade de dados

Use dimensões para transformar “dado bom” em critérios objetivos.

Dimensão	Pergunta operacional	Exemplo de check
Compleitude	Campos obrigatórios existem?	order_id IS NOT NULL
Unicidade	Há duplicidades indevidas?	COUNT por chave = 1
Validade	Formato e domínio estão corretos?	status em lista permitida
Consistência	Campos relacionados fazem sentido juntos?	datas e valores coerentes
Atualidade	O dado chegou dentro do SLA?	última carga dentro do limite
Acurácia	O valor representa a realidade esperada?	reconciliação com fonte

5 PILARES DA OBSERVABILIDADE DE DADOS

CONFIÁVEL • TRANSPARENTE • GOVERNADO • EM TEMPO REAL



CONFIÁVEL
E ÍNTEGRO



ESCALÁVEL
E ELÁSTICO



OBSERVÁVEL
EM TEMPO REAL



GOVERNADO
E SEGURO

1

FRESCOR (FRESHNESS)

Os dados estão atualizados?



Última atualização
2 min atrás



Expectativa (SLA)
≤ 5 min



Status
SAUDÁVEL

2

VOLUME

Estamos recebendo o esperado?



Registros (24h)
128,4 M



Expectativa
100 M – 150 M



Status
SAUDÁVEL

4

QUALIDADE (QUALITY)

Os dados estão corretos e válidos?



Taxa de qualidade
99,21%



Expectativa (mín.)
≥ 98%



Registros inválidos
124.832



Status
ATENÇÃO

DELTA LAKE
STORAGE LAYER



UNITY CATALOG
GOVERNANÇA UNIFICADA

Metadados • Linhagem • Segurança • Auditoria

3

SCHEMA

A estrutura dos dados está conforme?



Alterações (24h)
0



Expectativa
Sem alterações
não autorizadas



Status
SAUDÁVEL

5

LINHAGEM (LINEAGE)

De onde vêm os dados e para onde vão?



Cobertura de linhagem
100%



Upstream
7 fontes



Downstream
9 ativos



Status
SAUDÁVEL

OBSERVABILIDADE CONTÍNUA



FONTES
E EVENTOS



INGESTÃO
(Streaming/Batch)



TRANSFORMAÇÕES
(Pipelines/Jobs)



CAMADAS
Bronze → Silver → Gold



CONSUMO
Dashboards / ML / APIs



ALERTAS E AÇÕES
Proativo e automatizado

BENEFÍCIOS

- ✓ Confiança nos dados em tempo real
- ✓ Detecção precoce de problemas
- ✓ SLA e qualidade garantidos
- ✓ Governança e compliance
- ✓ Decisões melhores e mais rápidas

Expectations em Lakeflow pipelines

Expectations aplicam constraints de qualidade diretamente no fluxo do pipeline.

Nome	Constraint	Ação
Identifica a regra e permite acompanhamento.	Expressão SQL booleana que avalia cada registro.	Permitir, descartar, falhar ou acompanhar violações.

- Expectations validam dados enquanto eles fluem por pipelines ETL.
- Elas geram métricas de qualidade e permitem falhar updates ou descartar registros inválidos.
- Use nomes de expectativas que comuniquem claramente o que está sendo validado.

Exemplo de checks de qualidade

Checks simples podem impedir erros silenciosos nas camadas finais.

```
CREATE OR REFRESH STREAMING TABLE silver_orders(  
  CONSTRAINT order_id_not_null EXPECT (order_id IS NOT NULL) ON VIOLATION DROP ROW,  
  CONSTRAINT amount_non_negative EXPECT (amount >= 0) ON VIOLATION FAIL UPDATE,  
  CONSTRAINT valid_order_date EXPECT (order_date IS NOT NULL) ON VIOLATION DROP ROW  
)  
AS SELECT * FROM STREAM(bronze_orders);
```

- DROP ROW pode isolar registros inválidos quando o pipeline deve continuar.
- FAIL UPDATE protege camadas críticas quando a violação não deve ser tolerada.
- A regra deve ter dono, racional e ação operacional documentados.

Quarentena e correção controlada

Nem todo dado inválido deve ser descartado sem rastro.

Quarentena

Guardar registros inválidos para análise.

Diagnóstico

Identificar causa: fonte, schema, regra ou transformação.

Reprocessamento

Corrigir causa e reexecutar escopo controlado.

- Quarentena facilita auditoria e aprendizado operacional.
- A decisão entre descartar, falhar ou isolar depende da criticidade do dado.
- Documente o motivo da rejeição, a regra violada e o caminho de correção.

Métricas de refresh, volume e schema

A demonstração deve mostrar evidência objetiva da saúde do pipeline.

Métrica	Pergunta respondida	Exemplo de sinal
Refresh	O dado está atualizado?	última carga, tempo desde última atualização
Volume	Recebemos o volume esperado?	linhas processadas/rejeitadas
Schema	A estrutura mudou?	colunas novas, ausentes, tipo divergente
Qualidade	O dado passou nos checks?	taxa de sucesso, regras violadas
Linhas inválidas	O que foi bloqueado?	quarentena por regra e camada



CHECKS DE QUALIDADE APLICADOS EM CADA GATE



NULOS

Verifica campos obrigatórios nulos

```
col("id").isNotNull()
```



DUPLICADOS

Identifica registros duplicados por chave

```
count(*) over (partition by id) = 1
```



SCHEMA

Valida tipos, colunas e evolução do schema

```
expectSchemaMatch()
```



FAIXAS (RANGES)

Verifica limites e valores esperados

```
col("amount").between(0, 100000)
```



FRESCURA


Verifica atraso máximo do dado (freshness)

```
current_timestamp() - col("event_ts") == interval 15 minutes
```

OBSERVABILIDADE & MÉTRICAS



- ✓ Taxa de sucesso por gate
- ✓ Volume processado / rejeitado
- ✓ Top motivos de falha
- ✓ Atraso (latência) do pipeline
- ✓ Alertas e notificações



FLUXO DE QUARENTENA PARA REGISTROS INVÁLIDOS



REGISTRO INVÁLIDO

Falha em um ou mais checks do gate



QUARENTENA (Delta Table)

Registros isolados para análise e correção



ANÁLISE & CORREÇÃO

Investigar causa raiz e corrigir dados na origem



REPROCESSO CONTROLADO

Reexecutar somente o que foi corrigido (idempotente)

PRINCÍPIOS APLICADOS



Qualidade como parte do pipeline (Não é opcional)



Fail fast

Detecta cedo para proteger camadas a jusante



Idempotência

Reprocesso seguro e controlado



Governança

Auditoria, lineage e rastreabilidade



Confiança no dado

Dado certo, no tempo certo, para a decisão certa



DICA DE OURO

Nunca promova dados com falha de qualidade. Quarentena, corrija e reprocessa. Assim mantemos o Gold confiável.

Os 5 pilares em linguagem operacional

Cada pilar responde uma pergunta que ajuda a operar o dado.

Pilar	Pergunta prática
Frescor	O dado chegou no tempo esperado?
Volume	A quantidade processada está dentro do padrão?
Schema	A estrutura ainda é compatível com consumidores?
Qualidade	As regras e métricas estão dentro do limite?
Linhagem	De onde veio, para onde vai e quem depende?

Mensagem

Sem observabilidade, o pipeline pode falhar silenciosamente mesmo quando o job aparece como concluído.

Data quality monitoring

Monitoramento ajuda a acompanhar frescor, completude, perfil estatístico e anomalias.

Anomaly detection

Monitora frescor e completude com histórico.

Data profiling

Mede distribuição e estatísticas ao longo do tempo.

Alerts

Sinaliza alterações fora do esperado.

- Data quality monitoring ajuda a garantir qualidade dos ativos em Unity Catalog.
- Anomaly detection analisa padrões históricos para frescor e completude.
- Data profiling captura métricas históricas de distribuição para acompanhar integridade e mudanças.

Estratégia de observabilidade enterprise

Observabilidade precisa cobrir plataforma, workloads, qualidade e custo.

Área	Exemplo de monitoramento
System tables	Uso, performance, custos, segurança e compliance
Job runs	Histórico, duração, falhas e tendências
Pipeline monitoring	Status, expectativas, latência e lineage
Spark performance	Skew, spill, tarefas longas e gargalos
Data quality	Frescor, completude, schema e drift
Alertas	SLA, falha crítica e anomalias

Governança e Unity Catalog

Governança torna dados descobríveis, protegidos, auditáveis e rastreáveis.

Acesso

Privilégios, row filters e column masks quando aplicável.

Catálogo

Metastore, catálogo, schema e tabelas organizados.

Auditoria

Quem acessou, transformou ou consumiu dados.

- A governança precisa refletir domínios, ambientes e criticidade dos dados.
- O desenho de catálogo e schema deve estar alinhado ao modelo de governança da organização.
- No contexto do treinamento, a arquitetura usa catálogos por ambiente e camadas por domínio.

Lineage e análise de impacto

Lineage responde de onde o dado veio, como mudou e quem depende dele.

Impact analysis

Antes de mudar uma coluna ou tabela, veja dependências.

Root cause

Quando o dashboard diverge, rastreie fontes upstream.

Compliance

Rastreie fluxo de dados sensíveis e consumo downstream.

- Unity Catalog captura lineage automaticamente para queries executadas no Databricks, inclusive em nível de coluna.
- O lineage mostra quais queries/arquivos populam uma tabela, quais jobs/notebooks transformam e quais dashboards consomem.
- Lineage é essencial para troubleshooting e mudança segura.


Critérios para escolher a stack

Não escolha tecnologia por preferência. Escolha por requisitos, operação e governança.

Critério	Pergunta para decisão
Latência	Batch, incremental ou streaming?
Governança	Quem pode acessar, auditar e rastrear?
Escala	Volume, frequência, concorrência e SLA?
Qualidade	Quais checks bloqueiam publicação?
Operação	Quem monitora, corrige e reprocessa?
Custo	Qual custo aceitável por carga e por ambiente?
IA/Analytics	O dado está pronto para BI, ML, GenAI ou APIs?

Lakehouse para Analytics e IA

A arquitetura deve servir dashboards, APIs, modelos e agentes sem duplicar governança.



- O mesmo Lakehouse sustenta consumo analítico e aplicações de IA quando a base é governada.
- Qualidade e lineage reduzem risco de respostas incorretas e decisões sem lastro.
- A arquitetura final deve explicitar como dados confiáveis chegam ao consumo.

HANDS-ON INTEGRATED CHALLENGE

FINAL MINI PROJECT

CONSTRUA UM PIPELINE LAKEHOUSE COMPLETO, CONFIÁVEL E OPERÁVEL

CONFIÁVEL
E IDEMPOTENTE

ESCALÁVEL
E ELÁSTICO

OBSERVÁVEL
E MONITORADO

GOVERNADO
E AUDITÁVEL

O DESAFIO FINAL

Seu time deverá entregar um pipeline end-to-end no Databricks Lakehouse, desde a ingestão até a publicação para consumo analítico, com qualidade, orquestração, monitoramento e apresentação final.

SEU TIME

Data Engineer
Pipelines e Transformações

Data Quality Engineer
Regras e Testes

DevOps / DataOps Engineer
Jobs, CI/CD e Infra

Data Analyst
Consumo e Métricas

Tech Lead
Arquitetura e Governança

ENTREGA DO PROJETO

- ✓ Pipeline completo e funcional
- ✓ Jobs orquestrados e monitorados
- ✓ Quality checks com expectativas
- ✓ Dados publicados na camada Gold
- ✓ Dashboards e métricas de negócio
- ✓ Apresentação final (10 minutos)

OBJETIVO

Dados confiáveis e de valor contínuo, gerando insights em tempo real e em batch.

PIPELINE LAKEHOUSE END-TO-END

1. INGESTÃO

Capture

APIs, Arquivos, Bancos, IoT, Kafka...

2. BRONZE

Dados Brutos

Imutável, rastreável, sem alteração

3. SILVER

Dados Conformados

Limpeza, tipagem, deduplicação, enriquecimento e validações

4. GOLD

Dados de Negócio

Agregações, métricas e modelos para consumo

5. PUBLICAÇÃO

Consumo Analítico

Dashboards, BI, APIs, Data Science

ORQUESTRAÇÃO COM DATABRICKS JOBS

Trigger (Agendado / Evento)

Ingestão Bronze → Bronze → Silver → Quality Checks → Publicação Gold

RETRIES & RECOVERY

Tentativas automáticas com backoff exponencial

DEPENDÊNCIAS (DAG)

Execução controlada entre as tarefas

QUALIDADE DE DADOS (EXPECTATIONS)

```
CREATE STREAMING TABLE silver_orders
EXPECT (order_id IS NOT NULL) ON VIOLATION DROP ROW
EXPECT (amount > 0) ON VIOLATION FAIL UPDATE
EXPECT (order_date IS NOT NULL) ON VIOLATION DROP ROW
AS
SELECT * FROM bronze_orders;
```

Taxa de Sucesso: 98% ok

Linhas Processadas: 1.2 M

Falhas: 12

Linhas Inválidas: 4.3 K

Validações Contínuas

Quarentena de Inválidos

Gates de Qualidade

MONITORAMENTO & OBSERVABILIDADE

Jobs UI

Spark UI

Logs

Métricas

Alertas

Dashboards

Notificações

Lineagem

SAÚDE DO PIPELINE

Jobs: Ok

Qualidade: Ok

Dados: Ok

Disponibilidade: Ok

APRESENTAÇÃO FINAL

10 MINUTOS

- O problema e a solução
- Arquitetura e decisões
- Demonstração do pipeline
- Qualidade e confiabilidade
- Insights gerados
- Lições aprendidas

Checklist da Arquitetura Final

Se algum item não está claro, o mini projeto precisa explicitar a decisão.

Bloco	Critério de aceite
Fontes	Origem e frequência declaradas
Bronze	Dados brutos preservados e rastreáveis
Silver	Limpeza, tipagem, deduplicação e validações
Gold	Modelo de consumo e métricas de negócio
Jobs	DAG com dependências, parâmetros e retry
Qualidade	Checks, falhas e evidências
Governança	Catálogo, schema, owner, lineage e acesso
Observabilidade	Métricas de refresh, volume, schema e falhas



CONFIÁVEL
E ÍNTEGRO



COLABORATIVO
E GOVERNADO



ESCALÁVEL
E ELÁSTICO



OBSERVÁVEL
E RASTREÁVEL



INTELIGENTE
E PRONTO PARA IA

FONTES DE DADOS



APIs / REST



BANCOS
DE DADOS



ARQUIVOS
EM CLOUD



STREAMING
(KAFKA / EVENT HUBS)



APLICAÇÕES
SaaS / ERP / CRM



DISPOSITIVOS
IoT

ORQUESTRAÇÃO COM DATABRICKS JOBS (LAKEFLOW JOBS)



Ingestão



Validação
Schema & DQ



Transformações



Agregações
e Regras



Publicação
Gold



Notificações
e Alertas




TRIGGERS

Agendado
Baseado em Evento
Ou Ad-hoc

LAKEHOUSE - ARQUITETURA MEDALLION

LANDING

Zona de Recepção



JSON CSV PARQUET AVRO

Dados imutáveis
e rastreáveis

DATA QUALITY GATES

- Schema Check
- Tipos e Nulos
- Regras de Negócio
- Referencial
- Duplicidade
- Faixa de Valores
- Expectations

BLOQUEIA / ALERTA
OU ISOLA

BRONZE

Dados Brutos



JSON CSV LOG PARQUET

Imutáveis e
auditáveis

DATA QUALITY GATES

- Schema Check
- Tipos e Nulos
- Regras de Negócio
- Referencial
- Duplicidade
- Faixa de Valores
- Expectations

BLOQUEIA / ALERTA
OU ISOLA

SILVER

Dados Limpos
e Validados



Conformados e
auditáveis

DATA QUALITY GATES

- Schema Check
- Tipos e Nulos
- Regras de Negócio
- Referencial
- Duplicidade
- Faixa de Valores
- Expectations

BLOQUEIA / ALERTA
OU ISOLA

GOLD

Dados de Negócio
(Modelados)



Modelados e prontos
para consumo analítico

CONSUMO E VALOR

ANALYTICS / BI



DASHBOARDS EXECUTIVOS



APLICAÇÕES & APIS



DATA SCIENCE & AI



GOVERNANÇA & CATÁLOGO DE DADOS - UNITY CATALOG



CATÁLOGOS



SCHEMAS



TABELAS



FUNÇÕES



PRIVILÉGIOS



ROW / COLUMN
LEVEL SECURITY



AUDITORIA
E LINHAGEM

LINHAGEM & IMPACTO



Rastreabilidade ponta a ponta • Impacto • Ancestralidade • Data Lineage

OBSERVABILIDADE & MONITORAMENTO

PIPELINES

12

Ativos

DURAÇÃO MÉDIA

18m 42s

SUCESSO

95.4%

FALHAS

2

DADOS PROCESSADOS

1.2 TB

LOGS

MÉTRICAS

ALERTAS

CUSTOS

SLA / SLO

FLUXO OPERACIONAL



Código & Notebooks



Git & Versionamento



CI / CD



Deploy (DEV)



Testes & DQ Gates



Deploy (QA)



Deploy (PROD)

PRINCÍPIOS DATAOPS



Confiabilidade



Automação



Colaboração



Qualidade



Observabilidade

DESAFIO INTEGRADO - FIM A FIM



Construir pipeline
batch + streaming



Aplicar DQ
e expectations



Orquestrar com
Jobs



Publicar camadas
Bronze, Silver, Gold



Entregar valor com
dashboards / APIs



Exemplo de teste final de qualidade


O teste deve ser simples, explícito e bloqueante quando necessário.

```
# quality_check.py
from pyspark.sql import functions as F

orders = spark.table(f'{catalog}.silver.orders')
checks = {
    'order_id_not_null': orders.filter(F.col('order_id').isNull()).count(),
    'amount_non_negative': orders.filter(F.col('amount') < 0).count(),
    'order_date_valid': orders.filter(F.col('order_date').isNull()).count()
}
failed = {k:v for k,v in checks.items() if v > 0}
if failed:
    raise Exception(f'Quality gate failed: {failed}')
```

Fechamento da trilha

De notebooks para produtos de dados confiáveis, governados e prontos para Analytics e IA.



- O desafio final evidencia a maturidade adquirida na trilha.
- Uma boa solução Databricks não termina quando o código roda, mas quando alguém consegue confiar, operar e evoluir o pipeline.
- Próximo passo sugerido: transformar os melhores mini projetos em templates reutilizáveis para novos workloads.

Fim do Day 10 e do Bootcamp

Thank you.

Make it real.

Capgemini 